

ML-Predicción

Sismicidad Global

Predicción de terremotos significativos mediante clasificación binaria

Proyecto Machine Learning

46.419

terremotos

2000-2025

período

Decision Tree

modelo final

Problema de Negocio

Los terremotos son uno de los fenómenos naturales más destructivos del planeta, pero no todos tienen el mismo impacto. La ubicación geográfica y la profundidad son factores clave para determinar su gravedad.

Objetivo

Dado un terremoto con sus coordenadas geográficas y profundidad, predecir si será significativo ($\text{magnitud} \geq 6.0$) o no. Aplicación directa en gestión de riesgos y sistemas de alerta temprana.



Planificación urbana



Alertas tempranas




Gestión de riesgos

Planteamiento Técnico

 Tipo de problema: Clasificación binaria supervisada

Pipeline



Features utilizadas

Latitud	Original	Longitud	Original	Profundidad	Original
cinturon_fuego	Engineered	prof_grupo	Engineered	mes / año	Engineered

Hallazgos del EDA



Patrón geográfico claro

Los terremotos significativos se concentran en el Cinturón de Fuego del Pacífico. La ubicación geográfica es un predictor clave.



Profundidad diferenciada

Los terremotos severos tienden a ocurrir a profundidades intermedias. Los terremotos muy profundos son menos frecuentemente significativos.



Desbalanceo 11:1

Solo el 8.3% de los registros son terremotos severos. Esto requiere métricas adaptadas y técnicas de balanceo como SMOTE.



Baja multicolinealidad

Las features numéricas (latitud, longitud, profundidad) no presentan correlación alta entre sí — buena señal para el modelado.

Dataset

 46.419

registros totales

 2000–2025

25 años de datos

 USGS

fuentes oficiales

 8.3%

clase minoritaria

Variables principales:

 Latitud

 Longitud

↓ Profundidad (km)

 Fecha

 Magnitud Richter
(target)

Variable Target & Desbalanceo

```
df["es_severo"] = (df["magnitud"] >= 6.0).astype(int)
```

0 — Leve / Moderado

Magnitud < 6.0

42.549 registros • 91.7%

1 — Significativo

Magnitud ≥ 6.0

3.870 registros • 8.3%

⚠ Desbalanceo 11:1 → Implicaciones

Un modelo que prediga siempre "0" tendría 91.7% de accuracy → métrica engañosa.

Solución: usar F1-Score y ROC-AUC como métricas principales + SMOTE para balancear.

Comparativa de Modelos

Modelo	F1 (CV)	Observaciones
DummyClassifier (baseline)	0.0000	Siempre predice clase mayoritaria
Logistic Regression	0.1654	Modelo lineal, poco poder con datos no lineales
KNN	0.0357	Sin class_weight, peor en desbalanceo
Random Forest	0.0469	Promediado de árboles perjudica recall
✓ Decision Tree	0.1968 → 0.2397	Mejor F1 tras GridSearchCV (max_depth=5)

Resultados Finales

✓ **Modelo final: Decision Tree + SMOTE · Umbral: 0.5 (prioriza recall)**

0.2276

F1-Score

59%

Recall
clase severo

53%

Recall
sin SMOTE

💡 **¿Por qué SMOTE mejora el recall de 53% a 59%?**

SMOTE genera ejemplos sintéticos de la clase minoritaria, ayudando al modelo a aprender mejor las características de los terremotos severos.

🔔 **Decisión de negocio:** en un sistema de alerta es preferible una falsa alarma a no detectar un terremoto severo → priorizamos recall sobre F1.

Conclusiones & Próximos Pasos

✓ La ubicación geográfica y la profundidad son predictores relevantes de la severidad de un terremoto.

✓ Decision Tree con SMOTE logra detectar el 59% de los terremotos severos, mejorando el baseline (0%).

✓ El desbalanceo 11:1 requiere métricas adaptadas (F1, ROC-AUC) y técnicas de balanceo.

⚠ F1 de 0.23 indica margen de mejora — el modelo tiene limitaciones que deben comunicarse.

Próximos pasos:

Incorporar datos de placas tectónicas · Probar XGBoost / LightGBM · Ampliar features geológicas